

AI CUP 2026 春季賽

基於時序資料之桌球戰術與結果預測競賽 技術報告

隊伍：TEAM_10106

隊員：陳盛茂（隊長）、陳冠宇、黃柏瑜

指導教授：英家慶

是否有意願參與 2026 IEEE International Conference on Big Data Workshops 發表：☒是 ☐否

壹、環境

作業系統：Windows 11。程式語言：Python 3.11.9（Windows py launcher）。運算硬體：單張 NVIDIA GeForce RTX 4090 24GB（CUDA 12.1）；本隊政策為「一律使用 GPU 訓練」。

主要函式庫（版本已於 requirements.txt 釘選）：LightGBM 4.6.0、XGBoost 3.2.0、CatBoost 1.2.10、scikit-learn 1.6.1、PyTorch 2.5.1+cu121、NumPy 2.4.3、pandas 2.3.3、SciPy 1.17.1。

預訓練模型：未使用任何外部預訓練模型。報告中 Transformer encoder 的自監督預訓練（masked-stroke-modeling）完全以本競賽資料為語料（train 全拍 + test 之 visible 拍），不含任何外部 corpus。

額外資料集：最終提交未使用任何外部資料集。本隊曾研究 ShuttleSet22（羽球）、TTStroke-21、TTSwing、OpenTTGames 等候選，但實測 cross-domain 遷移為負或零，全部捨棄（詳見捌）。

生成式 AI 使用揭露

本隊使用 Anthropic Claude（Claude Code / Claude Opus 系列）為 AI 協作助手，採「harness engineer（人類編排、AI 實作）」分工：

- **人類團隊**：設定戰略與每日目標、領域判斷；跑訓練、上傳 leaderboard 並回饋；一切對外與不可逆的最終決定（slot 選擇、定版、否決權）。
- **Claude（AI 助手）**：與團隊共同規劃；撰寫資料處理、訓練、評估程式碼；編排與本機驗證實驗；維護規則庫與實驗紀錄。
- **迭代循環**：共同規劃 → Claude 實作並本機評估 → 團隊上傳 LB 並回饋 → 共同評估方向 → 繼續實作。

本報告由 Claude 協助撰寫，方法與數據均經團隊核實；提交之 CSV 為純模型輸出。

貳、演算方法與模型架構

整體架構：三軸獨立建模 × 三階段選擇性疊加（overlay）。三個預測目標——actionId（擊球動作 15 類，目標落 0–14）、pointId（落點 / 回合結果 10 類）、serverGetPoint（二元，AUC 計分）——各自建模後三階段組裝；每階段皆為純模型輸出，並先在 player-held-out OOF 確認 macro-F1 上升才套到測試集。

2.1 Action 軸 — 雙路 (seen GBDT / OOV Transformer) + OOV-gating

(a) 生產線 GBDT 集成 (用於 842 條 seen-球員 rally) : LightGBM + XGBoost + CatBoost 對 15 類做 multiclass softprob, 機率平均集成 (權重 0.45 / 0.30 / 0.25) 。多源整合以 Nelder-Mead 在 action 軸做凸組合 (point / server 維持純基底), 通過 4 道 gate (standard OOF、test-PMF 加權 OOF、rare player $\wedge$ pair、disagreement value, ≥ 3 通過) 才採用; 另含物理軸 overlay (G_PHYS, 依 comb / spin 修正 67 cell) 。

(b) Transformer-Transductive (用於 1,003 條 OOV-球員 rally, 模型 v1080) : GBDT 之 player target-encoding 對 31 名未見球員無編碼可查、預測崩潰; 改以「序列前綴風格 + 透析 context」取代 player-id。Encoder 為 masked-stroke-modeling 自監督預訓練之 stroke encoder; 多任務頭 (action 15 + point 10 + server 1) 共享 trunk, pooled = [last-valid || masked-mean || attn-pool || ctx || transductive]。Player embedding 完全停用, 改以 16 維「截斷對齊」透析向量投影注入, 無先驗時零向量 graceful 退化。反洩漏: encoder 只看前綴 1..K, 第 K+1 拍與 serverGetPoint 永不進入。

(c) OOV-gating 部署: 每條 rally 若 gameId 或 gameIdOther 任一未在訓練集出現即判 OOV (共 1,003 條), 採 v1080 action; 其餘 842 條 seen rally 維持生產線 GBDT。

2.2 Point 軸 — within-match 透析 + 選擇性 overlay

pointId 本質難以預測 (終局拍隨機刪除, 使第 K+1 拍落點近隨機)。策略: 不整軸取代, 只對低支持落點區 (drag zone {1,3,4,5}) 做少量、高信心 overlay——以 v85 GBDT point 機率為底, 疊 v701 (within-match 透析 base) 與 v1341 (最終 41 個 high-margin flips)。每條 overlay 皆先在 OOF 以相同 cap、margin gate、p0_rate 帶與漂移檢查通過後才套測試集。

2.3 Server 軸 — score-progression 模型

部署 server = G14 (score-progression) + v951 (正交 within-rally ML) 以 $\alpha=0.08$ 加權, 輸出 float 機率 (mean ≈ 0.52)、rally-level AUC ≈ 0.82 。模型以桌球計分與「每 2 分換發」為基礎, 由相鄰 rally 之比分變化學習推估 serverGetPoint。

資料使用說明: 本軸有使用 test.csv 之內容——test 中合法保留之 scoreSelf / scoreOther 與 rally 順序 (rally_id)——作為特徵; 提交 CSV 為純模型輸出。對照基準: 純 within-rally 之乾淨 ML server 上限約 AUC 0.666。

2.4 關鍵參數摘要 (詳見伍)

GBDT: lr 0.05–0.06、depth 7 / num_leaves 95、5-fold GroupKFold(by match)、集成權重 0.45/0.30/0.25。Transformer: AdamW lr 1e-3、weight_decay 0.05、CosineAnnealingLR、40 epochs、batch 256、early-stop patience 8、StratifiedGroupKFold(by 擊球者)、test refit seeds (42,43,44) 平均。

參、創新性

本題最大難點為分佈偏移: 測試集 71 名球員中 31 名 (共 1,003 / 1,845 條 rally) 未在訓練集, 測試 match 與訓練 match 100% 不重疊。本隊創新皆圍繞「未見球員 / 未見場次下穩健預測」展開。

創新一：OOV-aware 雙路 action 架構（本題最大分佈偏移的乾淨解，亦為最終分數的真實來源）

傳統 GBDT 依賴 player / pair target-encoding，遇未見球員即崩潰。本隊改以「**player-agnostic Transformer + 透析風格前綴**」取代 player-id：完全停用 player embedding，改用 16 維「截斷對齊」透析向量（僅取該擊球者於同場較早 rally 的風格脈絡）投影注入，無先驗時零向量 graceful 退化；再以 OOV-gating 把 1,003 條 OOV rally action 換成此 Transformer、842 條 seen rally 維持生產線 GBDT。此為本競賽**唯一成功正向轉移之 action overlay（Stage-2 Public LB +0.0066）**。

創新二：within-match leave-self-out 透析條件機率（鏡射測試情境的 point 軸設計）

測試 match 與訓練 match 完全不重疊，任何「跨 match」玩家統計皆失效。我們讓 point 條件訊號**只來自 rally 所在 match 的其他拍**（leave-self-out：train 側移除自身、test 側目標拍本就隱藏），精確鏡射測試情境、OOV-safe；在此 base 上僅做少量、高信心 drag-zone overlay，穩定回收 low-support 落點。

創新三：AICUP-only 自監督預訓練、player-grouped 驗證、LB 分解數學（方法論創新）

- **自監督預訓練**：masked-stroke-modeling，語料僅本競賽 train（全拍）+ test（visible 拍），零外部資料。
- **OOV-honest 驗證**：改用 player-grouped StratifiedGroupKFold（連 inner early-stop split 亦球員互斥），對齊「30% 全新球員」之真實測試難度、杜絕 seen-player 選模假象。
- **LB 分解數學**：依官方公式 $\text{Overall} = 0.4 \times \text{Action_F1} + 0.4 \times \text{Point_F1} + 0.2 \times \text{Server_AUC}$ ，以各軸 OOF 代入於上傳前預測 LB（某次預測 0.3848、實際 0.3850，誤差 < 0.0001 ），大幅減少無效上傳。

創新四：server 軸 ML 上限光譜之徹底量測（方法論貢獻）

本隊以五法（三 GBDT + 單一 / ensemble 神經 solver）量測 server 軸不同 ML 設計於真實 test 之 AUC，得一條光譜：純 within-rally ML 0.666、比分特徵 GBDT ~ 0.71 、神經 solver 封頂 ~ 0.78 、算術重建 0.82。此光譜呈現一個**可量測且可重現之邊界——神經 solver 與精確整數聯立之間約 0.04 AUC 不可學落差**。另附完整合規之「全 ML 變體」對照，供後續研究直接複用此基準。

肆、資料處理

	rallies	strokes	matches	players
train.csv	14,995	84,707	216	166
test.csv	1,845	5,668 (visible)	79	71 (其中 31 名 OOV)

反洩漏與目標定義：載入 test 後立即 drop serverGetPoint（主辦叮嚀 + 反洩漏保險）；訓練 target 僅取 strikeNumber ≥ 2 且 actionId < 15 的非發球拍（serve 15–18 永不為目標）；action==0 $\rightarrow$ point==0 約束在所有組裝時強制套用。

對齊測試短 context 的兩項處理：(1) 隨機尾端截斷 bagging——每條 train rally 抽 $N=4$ 個截斷目標位置，mimic 測試的短 context 分佈；(2) test-matched 重要性加權——以 test visible-length PMF（測試平均 visible 僅 3.07 拍）對 train 樣本做重要性校正。

兩段式 point：Stage-1 二元（終結 class 0 vs 落區 1–9）+ Stage-2 九類落區；最終 $p_0 = P(\text{終結})$ 、 $p_k = P(\text{非終結}) \cdot P(\text{zone}=k | \text{非終結})$ 。

within-match 透析特徵：建立 per-(match, 擊球者) 的 leave-self-out 條件機率（train 側移除該列自身 one-hot、test 側目標拍本就隱藏），條件池來自該 rally 自己 match 的拍（0 train-match 重疊、OOV-safe）。因 test 目標拍自身的 spin / strength / hand / position 未知，訓練時亦將這些欄位 mask 成 -1，確保 train / test parity。

Transformer 序列前處理：build_sequences 將每條 rally 轉為 stroke 序列、make_prefix_batch 只取前綴 1..K、target_context 取目標脈絡、canonical_target_rows 對齊全鍵一致列順序；另建 16 維截斷對齊透析向量（僅取同場較早 rally，依 test K-visible PMF 比例對齊）。自監督語料 = train 全拍 + test visible 拍（無標註，僅作 representation 學習）。

GBDT 主特徵（約 135 維）：categorical lag（prev1–5）、球員 / 配對 per-fold target-encoding、發球特徵、比分特徵、回合內累積計數，以及對手 matchup 轉移張量（在 GroupKFold inner loop 內、僅用 TR 側計算，防全域洩漏）。

資料更正與增補：訓練資料無缺漏標註，故無需刪除；「增補」主要為前述隨機尾端截斷增強（每條 rally 4 個截斷視角）與 test visible 拍之無標註利用（自監督語料、within-match 條件池、透析向量）。所有 test 端利用皆屬主辦明文允許之「已知歷程」，未觸及第 $K+1$ 拍標籤，且載入時即移除 serverGetPoint。

伍、訓練方式

交叉驗證一致性（防 OOF→LB 過擬合）：生產線 GBDT 用 GroupKFold(by match)；within-match point 同時跑 match-held-out 與 player-held-out，以 player-held-out OOF 作 OOV-honest production OOF；Transformer 用 StratifiedGroupKFold(by 擊球者)，inner early-stop split 亦球員互斥。所有 target-encoding / matchup 轉移張量皆在 fold 內、僅用 TR 側計算；test 推論的 row 篩選必與 train target filter 完全一致（避免 serve 拍等 OOD input 稀釋訊號）。

整體訓練流程四步：(1) 各軸、各來源模型皆以對應 GroupKFold 切分產生 OOF 與測試集預測；(2) 在 OOF 上以數值 gate（macro-F1 增益、rare class 不退步、 p_0 _rate 帶內、漂移低於門檻）模擬每個 overlay 與 blend，僅留通過者；若任一 gate 未過，該候選一律不採用、退回上一已驗版本；(3) 以純 numpy 確定性運算逐軸組裝、逐階段比對；(4) 上傳 leaderboard 回饋後更新規則庫。全程嚴守「先在 player-held-out OOF 驗證、再套測試集」與「production 為純模型輸出」兩條紀律。

5.1 生產線 GBDT 超參 (v23_config.py)

模型	關鍵參數	迭代 / early-stop
----	------	-----------------

LightGBM	multiclass, lr 0.05, num_leaves 95, feat_frac 0.8, bagging 0.85/freq5, reg_α0.1/λ0.2, device=gpu	2000 / 120
XGBoost	multi:softprob, lr 0.06, max_depth 7, subsample 0.85, colsample 0.8, device=cuda(hist)	1500 / 100
CatBoost	MultiClass, lr 0.06, depth 7, l2 3.0, Bernoulli 0.85, task_type=GPU	2000 / 100
集成權重	LGB 0.45 / XGB 0.30 / CB 0.25 ; CV : 5-fold, seed 42, GroupKFold(by match)	—

5.2 Transformer v1080 超參 (v1080_train.py)

項目	設定
優化 / 排程	AdamW (LR 1e-3, weight_decay 0.05) + CosineAnnealingLR; grad-clip 2.0
epochs / batch / early-stop	EPOCHS 40, BATCH 256, patience 8
損失	class-weighted CE (action/point) + 0.3·BCE (server) ; label smoothing 0.05
class weights / 截斷增強	1/sqrt(count+1) 正規化; trunc_augment p=0.5, 依 TEST_K_PMF_AUG
CV / seeds	StratifiedGroupKFold(5, by 擊球者); OOF seed 42; test refit seeds (42,43,44) 平均

Transformer 採兩階段訓練：先以 masked-stroke-modeling 在本競賽全部 strokes 上自監督預訓練，學得 stroke encoder 表徵；再載入該 encoder 做多任務 (action / point / server) 監督微調。微調以 trunc_augment 隨機截斷前綴 mimic 測試之短 context，五個 fold 各自 early-stop；最終測試預測以三 seed (42,43,44) refit 後平均，降低單一隨機種子之變異。

5.3 整合 / overlay / server 權重


- **v85 NM blend**：Nelder–Mead 30 restarts, seed 42; action-only 凸組合; 4-gate (≥ 3 通過才採用)。
- **v701 point overlay**： $\alpha=0.2$ (候選 {0.2,0.3,0.5})，DRAG {1,3,4,5}，cap 100， $p_0 \in [0.235, 0.290]$ ，margin gate，漂移檢查。
- **v1341 point overlay (最終, BAL 變體)**： $\alpha=0.3$ ，OOF 選中 margin 0.286，實際部署 41 flips (落點 {1,4,5})， $p_0=0.2499$ 。
- **server**：G14 (score-progression) + v951 (正交 ML)， $\alpha=0.08$ 。

overlay 權重非事後挑選： α 與 cap 均在 OOF 上以與部署相同規則模擬、取 macro-F1 最佳；例如 v1341 在 {0.2,0.3,0.5,0.7} $\times$ margin 網格上由 OOF 選出 $\alpha=0.3$ / margin=0.286，原封套至測試集，杜絕對測試集的後見之明。

重現性：附 code/05_assembly_and_outputs/reproduce_final.py，僅以本資料夾內檔案即可逐階段斷言、最終 byte-identical 重現提交檔 (已實測 exit 0)；各來源機率陣列已附為 artifact，組裝端為純 numpy 確定性運算。

陸、分析與結論

最終提交以三階段組裝，每階段皆為 LB-verified 正向 (圖一)。




圖一 三階段組裝之 Public LB 演進：0.4132 → 0.4141 → 0.4208 → 0.4225（每階段獨立 LB 驗證）。

階段	變更內容	Public LB
Base (agree1)	生產線 GBDT action(+G_PHYS) + v85 point + score-chain server	0.4132214
Stage 1	point 軸疊 within-match overlay (v701)	0.4141329
Stage 2	1,003 條 OOV rally action 換 Transformer (v1080, OOV-gated)	0.4207553
Stage 3 (最終)	41 個 high-margin drag-zone point flips (v1341 BAL)	0.4225088

6.1 各軸成效

- **Action**：OOV-honest f1a 約飽和於 ~0.43；雙路（seen GBDT / OOV Transformer）是對 31 名未見球員的最佳乾淨解，Stage-2 的 +0.0066 是本競賽唯一成功轉移的 action overlay。
- **Point**：受資訊論上限限制（終局拍隨機刪除 → 第 K+1 拍落點近隨機，next-stroke 文獻 NLL 1.79–2.18），只能以少量、高信心、drag-zone 的乾淨 overlay 穩定回收 low-support 落點。
- **Server**：乾淨 within-rally 上限約 AUC 0.666；部署採 score-progression (~0.82)，已於貳、三明列其特徵來源。我們亦以五法量測 ML 之上限光譜（圖二）：神經 solver 封頂 ~0.78，與算術 0.82 之間存在約 0.04 AUC 的不可學落差，可作為後續研究之基準。



圖二 server 軸 ML 上限光譜（於 overlap 真值量測）：乾淨 within-rally 0.666、比分特徵 GBDT ~0.71、神經 solver 0.78、算術 0.82。

6.2 成功與失敗例子

- **成功**：Day 31 以「軸交換 + LB 分解數學」預測 0.3848、實際 0.3850（誤差 < 0.0001 ）；Day 23 多源集成 action 在 LB 轉移優於單一最高 OOF 源（diversity $>$ 純 OOF 高度）。
- **失敗**（皆寫成規則避免重蹈）：Day 22 同時改造多軸 $\rightarrow -0.039$ ；逾 25 次 action overlay「OOF 漲、LB 跌」（CV 太鬆所致）；NN server 多 seed 集成 OOF 高達 0.92，但 LB -0.0026 ——當 test 相關性 $>$ OOF 相關性即為過擬合紅旗。

6.3 成績檢討：為何未進入更前段

最終 Public 0.4225088（628 隊） $\rightarrow$ Private 0.3643962，排名 40 / 423（前 9.5%）。對比乾淨最強隊約 0.44，落後約 0.02，主要源於三項方法不足：

- **太晚找到對的模型**：前 45 天多在 GBDT + Nelder–Mead blend 變體上反覆飽和，正確路線（classification-head transformer + player-grouped CV + prefix-style context）直到截止前 2–3 天才做出，無足夠時間做深、做進 seen 球員。
- **CV 方法論太鬆**：長期用 GroupKFold-by-match，但 match 內共享球員 $\rightarrow$ 驗證集比真實測試（30% 全新球員）容易太多 $\rightarrow$ 大量「OOF 漲、LB 不漲甚至跌」。正確做法為 player-grouped StratifiedGroupKFold，採用太晚。
- **早期 objective 不對**：早期把 ShuttleNet 直接 port，但其為連續座標 Gaussian 回歸 + best-of-N 生成評估，與本題單次預測、macro-F1 分類不同，導致「transformer 打不過 GBDT」的錯誤長期結論，封閉正確路線數週。

客觀事實：Public 前段分數（前五約 0.58–0.46）在數學上乾淨不可達（point 軸有資訊論天花板），與主辦明文禁止之「反向比對原始比賽影片」一致；該資料來源不公開、train $\leftrightarrow$ test rally 重疊為 0，本隊未走、亦不應走此路。但對乾淨前段約 0.02 落後仍屬自身方法失誤。

6.4 結論與未來方向

本隊最終交出完全乾淨、逐階段 LB 驗證、可由本資料夾腳本重現之 0.4225088 (Private 0.3643962)。未來改進：(1) 更早採 player-grouped StratifiedGroupKFold，避免 OOF→LB 失準；(2) classification-head Transformer 做深並推進到 seen 球員，而非僅 OOV-gating；(3) point 軸已近資訊論上限，邊際回收有限；(4) 探索純 within-rally server 之乾淨上限。將每一個失誤寫成可複用之規則與記憶，是本次協作之核心資產。

柒、程式碼

Github 連結：https://github.com/oomao/2026aicup_10106

程式碼包即本報告所附之 aicup_final_report/ 資料夾，含 README.md（安裝配置、模組輸入/輸出、重現步驟），涵蓋資料處理（code/01_data_preprocessing/）、各軸訓練（code/02_action_axis / code/03_point_axis / code/04_server_axis/）、與預測組裝（code/05_assembly_and_outputs/）。一鍵自包含重現：py aicup_final_report/code/05_assembly_and_outputs/reproduce_final.py（已驗 byte-identical，exit 0）。套件版本見 requirements.txt。

捌、使用的外部資源與參考文獻

外部資源：最終提交未使用任何外部資料集或外部預訓練模型。曾研究但實測遷移為負 / 零而捨棄之候選（ShuttleSet22、TTStroke-21、TTSwing、OpenTTGames 等）詳見 07_external_resources/。所用函式庫皆為開源。參考文獻（APA）：

- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30, 3146–3154.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. Advances in Neural Information Processing Systems, 31, 6638–6648.
- Paszke, A., Gross, S., Massa, F., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32, 8024–8035.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30, 5998–6008.
- Wang, W.-Y., Shuai, H.-H., Chang, K.-S., & Peng, W.-C. (2022). ShuttleNet: Position-aware fusion of rally progress and player styles for stroke forecasting in badminton. Proceedings of the AAAI Conference on Artificial Intelligence, 36(4), 4218–4226.